Auto-regi for videopodcast – evaluering og arkitektur

Oct 20, 2026 · @Magnus Lian

Dette er evalueringen og bakgrunnen for valgene. Den samlede app-spesifikasjonen som skal bygges ligger i fanen `App-spesifikasjon`, og gjelder der de to er uenige.

Kortversjon

Anbefaling: bygg en egen «regimotor» som lytter på RØDECaster-kanalene, tar beslutninger med en eksplisitt regelmotor og sender kutt via Companion til ATEM Mini Extreme ISO. Det er fullt gjennomførbart med hyllevare: alle ledd har dokumenterte grensesnitt, og ingen del krever ny forskning.

Det som skiller proff klipping fra «video følger lyd» er ikke reaksjonstid, men regi-grammatikk: bekreftet taletur før kutt, minimum bildelengde, ignorering av «mm/ja», egen håndtering av krysstale og latter, reaksjonsbilder og totaler med variasjon. VVD markedsfører 20 ms respons og switching-personligheter, men rask respons er nettopp det som gir nervøs klipping hvis reglene rundt ikke er strenge nok.

Sannsynlige årsaker til at dagens oppsett klipper dårlig (må verifiseres i studio):

- **Lekkasje mellom mikrofoner (bleed):** gjesten høres svakt i vertens mic, og systemet tror begge snakker.
- **Feil lydpunkt:** mates detektoren post-fader eller med main mix, påvirker fader og mute deteksjonen.
- **Korte innskudd:** latter, «mm» og hosting utløser kutt fordi bekreftelsestiden er for kort.
- **Ingen synlig forklaring:** når operatøren ikke ser *hvorfor* et kutt skjedde, er det umulig å tune.

Alt kjøres live, uten etterarbeid, på én Windows-PC med NVIDIA-skjermkort. Tre grep gir mest effekt: (1) per-kanal tale-deteksjon med nevralt nettverk pluss relativ nivåsammenligning, (2) en regelmotor der hvert kutt logges med årsak, og (3) «øyne»: ATEM-multiviewen tas inn via et capture-kort, slik at systemet ser munnbevegelse, ansikter og utsnitt. Bildet brukes til å bekrefte hvem som snakker, avvise lekkasje, velge reaksjonsbilder og rette opp utsnitt på kameraer som ikke er på lufta.

Markedsoversikt

De proffe visual radio-systemene løser samme problem som VVD, men legger mer vekt på regi-logikk, PTZ-innramming og integrasjon. Visual Radio Assist er nærmest det dere vil bygge, og bør prøves som referanse før egenutvikling.

Produkt	Deteksjon og regi	Kobling mot utstyr	Pris (oppgitt)	Relevans for dere
VVD 6	Nevral VAD + relativ nivåanalyse, «personligheter», fuzzy logic for reaksjonsbilder	ATEM, vMix, OBS, VISCA, Companion-modul; lyd via WASAPI/ASIO/NDI/Dante	Lite US$69, Standard US$169, Pro US$220	Dagens løsning. Billig og bred, men regi-logikken er lite transparent
Visual Radio Assist	Audio Triggers per mic, automasjoner, Camera Assist som rammer inn PTZ mens kamera er off air	ATEM, vMix, OBS, NDI/SDI-grafikk, egen Companion-modul og HTTP-API	Månedlig, Lite til Enterprise	Beste mønster å kopiere: lyd bestemmer *når*, kamerasystemet bestemmer *hvordan*
Broadcast Bionics CameraOne / BionicDirector	Egen auto-switch-algoritme	Laget for ATEM Mini-serien; demonstrert med RØDECaster + ATEM Mini	CameraOne ca. US$995 for 4 kamera (2021)	Direkte konkurrent for akkurat deres utstyr
multiCAM Radio	AI vekter hvem som snakker mest, dynamikk justerbar live	Eget system, integrert med radioautomasjon	Ikke oppgitt	Broadcast-klasse (RTL Belgia), tungt for podcast
VidiGo Visual Radio	Nivåbasert switching + grafikk og klippstart	Egen videomotor, Panasonic PTZ	Ikke oppgitt	Broadcast-klasse (ABC Radio National)
WinMedia WinCam 2.5	Nivåbasert + automatisk tracking, AI-styrt split-screen	Eget system	Ikke oppgitt	Interessant idé: split-screen ved krysstale
ChyronHego Visual Radio	Lyd + XML fra radioautomasjon, DVE og grafikk	Eget system	Ikke oppgitt	Radio-fokus, lite relevant for podcast

Fellestrekk hos de proffe: de skiller *når* det skal klippes (lyd) fra *hvordan* bildet ser ut (forhåndsdefinerte vinkler), de flytter aldri et kamera som er på lufta, og de lar operatøren overstyre med ett trykk. Eldre systemer som Broadcast Pix VOX hadde allerede regler mot kutt på hoste og enkeltord, så det er etablert praksis, ikke nyvinning.

SOTA-teknologi

Med én mikrofon per person er lyd alene nok til å vite hvem som snakker; det vanskelige er å skille ekte tale fra lekkasje og småord. Riktig stabel er fem lag: de tre første er lyd og regler og er obligatoriske, de to siste er videolaget.

Lag	Teknologi	Hva den løser	Kostnad i drift
1. Tale-deteksjon per kanal	Silero VAD (MIT, ONNX)	Skiller tale fra pust, bord-dunk, latter-støy. Under 1 ms per 30 ms lydblokk på én CPU-tråd	Ubetydelig, CPU
2. Dominans og bleed-avvisning	Egen kode: nivå i dB relativt til de andre kanalene, + lekkasjematrise målt ved oppsett	Gjestens stemme i vertens mic. Kanal regnes aktiv bare hvis VAD > terskel OG den ligger X dB over alle andre	Ubetydelig, CPU
3. Regimotor	Tilstandsmaskin med eksplisitte regler (se Klipperegler)	Bekreftelsestid, min/maks bildelengde, krysstale, reaksjonsbilder	Ubetydelig, CPU
4. Ansikt og munn	Ansiktsdetektor (SCRFD eller YuNet) + ansiktspunkter (MediaPipe Face Landmarker)	Finner hvem som er i bildet, munnåpning, hoderetning og smil per person	GPU, 10–15 bilder/s per kamera
5. Audiovisuell taler-deteksjon	Light-ASD: ca. 1 M parametere, 94,1 % mAP, 4,5 ms per bilde på RTX 3090	Kombinerer munnbevegelse med lyd og sier om personen i bildet faktisk er den som høres	GPU, lav

Tre funn påvirker designet direkte:

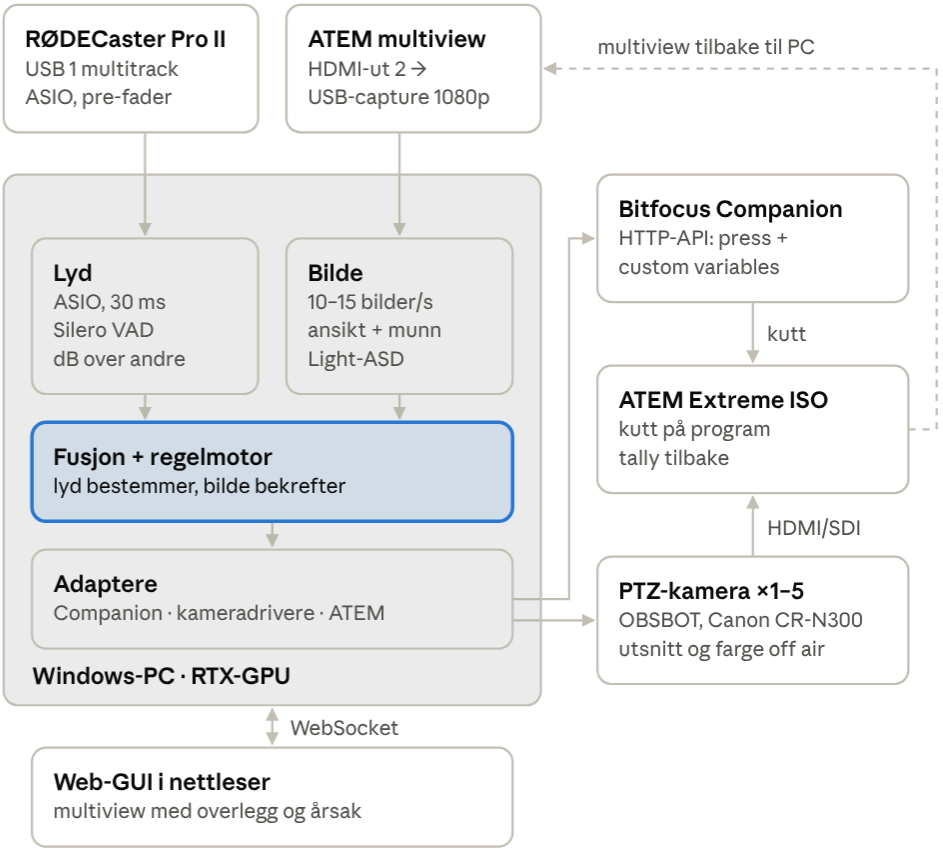
- **RØDECaster gir rene kanaler over USB.** USB 1 kan settes i multitrack, og hver kanal kan hentes ut pre-fader, så fader og mute ikke påvirker deteksjonen. Ingen splitterkabler trengs. På Windows leses sporene via RØDECaster sin ASIO-driver.
- **Lyd bestemmer, bilde bekrefter.** Med én mic per person er lyden raskest og sikrest. Bildet kommer 100–150 ms senere, og brukes derfor innenfor bekreftelsesvinduet som ja/nei og til å velge *hvilket* bilde, ikke til å starte kutt alene.

- **Kamerastyring og klipp skal være adskilt.** Visual Radio Assist sitt Camera Assist korrigerer innramming bare når kameraet er off air, og bestemmer ikke når det klippes. Samme prinsipp gjelder for utsnittskorrigering fra videolaget.

Arkitektur

Én Windows-PC i studio gjør hele jobben: den leser RØDECaster-kanalene, ser multiviewen fra ATEM, tar beslutninger og sender kommandoer til Companion og kameraene. Companion forblir laget dere kjenner, og Stream Deck kan fortsatt brukes til manuell overstyring.

Lyd bestemmer når, bildet bekrefter og rammer inn



signalflyt · lyd inn, kutt og kamerastyring ut

Regelmotoren er det eneste nye «smarte» leddet; alt annet er dokumenterte grensesnitt.

Ledd	Anbefalt valg på Windows	Merknad
Maskin	Windows 11 Pro, NVIDIA RTX-skjermkort, kablet nett	NVIDIA fordi ONNX Runtime med CUDA/TensorRT er best støttet. Companion kjører på samme PC
Lyd inn	RØDECaster ASIO-driver, USB 1 multitrack, pre-fader	Motoren eier ASIO-enheten. Ikke installer Virtual Devices-driveren: den er ikke kompatibel med ASIO
Video inn	ATEM HDMI-ut 2 satt til multiview → USB-capture 1080p (UVC). Ingen NDI	ATEM Mini Extreme har 2 HDMI-utganger og multiview med 4–16 ruter. Velg færrest mulig ruter som viser alle kameraene
Kjerne	Python 3.12 (asyncio): PortAudio/ASIO for lyd, OpenCV eller FFmpeg for capture, ONNX Runtime for modellene	Python fordi alle modellene finnes der. DirectML som reserve hvis GPU-en ikke er NVIDIA
Motor → Companion	HTTP Remote Control: `POST /api/location/<side>/<rad>/<kol>/press` og `POST /api/custom-variable/<navn>/value?value=…`	Companion kutter på ATEM. Én knapp per vinkel, som også lyser på Stream Deck
Motor ↔ ATEM (reserve)	PyATEMMax (Python) eller atem-connection	Leser tally og program-kilde; kan kutte direkte hvis Companion feiler
Motor → kameraer	Egen kameradriver per merke over IP (se Kamerastyring per modell)	Motoren styrer kameraene direkte, fordi utsnitt og farge krever posisjon og verdier tilbake
GUI	FastAPI + WebSocket, åpnes i nettleser på studionettet	Viser multiview med overlegg (ansiktsbokser, munn-indikator, fargeavvik) i 5 bilder/s

Ledd	Anbefalt valg på Windows	Merknad
Drift	Kjøres som Windows-tjeneste med autostart og vakthund	Windows Update og strømsparing styres utenfor sendetid; USB-strømsparing slås av

OBSBOT sin egen AI-tracking anbefales av under sending. Utsnitt rettes i stedet av videolaget, og bare på kameraer som ikke er på program.

Øyne: videolaget

Multiviewen gir systemet syn med én kabel, og viser nøyaktig det ATEM ser. Bildet brukes til å bekrefte og velge, mens lyden fortsatt starter kuttene, fordi bildet kommer 100–150 ms senere (anslag: capture + analyse).

Signal fra bildet	Brukes til	Regel
Munnbevegelse per person	Bekrefter at mic-en er ekte tale. Mic aktiv men munn i ro = lekkasje	V1
Ansikt funnet, størrelse og plassering	Kutter aldri til et tomt, halvt eller uskarpt bilde; velger total i stedet	V2
Audiovisuell taler-score (Light-ASD)	Avgjør ved krysstale, latter og hvis to deler mic	V1
Reaksjon: smil, nikk, hodebevegelse	Velger det mest levende reaksjonsbildet under lange svar	V3
Utsnittsfeil: hodeplass, blikkrom, bildestørrelse	Små VISCA-justeringer mens kameraet er off air	V4
Kamera i bevegelse	Vinkelen er ugyldig til bildet står stille	V5
Hoderetning mot en annen person	Forvarsel: øker prioriteten til den det ses mot (eksperimentelt)	V6

Oppløsningen er det viktigste å teste. I en 16-ruters multiview på 1080p er hver rute omtrent 480×270 piksler. Ansikter i nærbilder blir da store nok for munnanalyse, mens ansikter i totalen blir små. Light-ASD bruker ansiktsutsnitt på 112×112 piksler.

Hvis multiview ikke gir skarpe nok ansikter, er neste steg å ta kameraenes andre utgang direkte inn i PC-en, uten NDI. Canon CR-N300 har både HDMI og 3G-SDI, så SDI kan gå til ATEM eller en omformer mens HDMI går til et capture-kort med flere innganger. OBSBOT

Tail 2 har én HDMI-utgang, og trenger da en HDMI-splitter.

Videolaget gir også et raskere oppsett: hver person snakker noen sekunder, og systemet kobler selv mic til kamera ved å se hvem sin munn beveger seg.

Kamerastyring per modell

Alle merkene kan styres over IP, men med ulike protokoller. Motoren får derfor én felles kameradriver med samme kommandoer for alle, og en liten adapter per merke. Start med OBSBOT Tail 2 og Canon CR-N300.

Merke	Protokoll over IP	Farge og eksponering	Status
OBSBOT Tail 2	VISCA over IP (bekreftet av OBSBOT) + OSC for AI-tracking	Hvitbalanse via VISCA; om R/B-gain finnes må sjekkes i OBSBOTs VISCA-tabell	Fase 1
Canon CR-N300	Canon XC-protokoll (HTTP), VISCA over IP som reserve	Via XC: R/B, kelvin, iris, gain, lukker, metning. Kameraet må stå i manuell for å kunne styres	Fase 1
Panasonic AW-UE	HTTP-kommandoer `/cgi-bin/aw_ptz` og `/cgi-bin/aw_cam`	R-gain `OSG:39`, B-gain `OSG:3A` i AWB- eller VAR-modus. Minst 40 ms mellom bevegelseskommandoer	Fase 2
Sony BRC/SRG	VISCA over IP, UDP 52381	R/B-gain i manuell hvitbalanse	Fase 2

Felles kommandoer i driveren: hent preset, lagre preset, flytt litt (pan/tilt/zoom), les posisjon, sett hvitbalanse (kelvin eller R/B), sett eksponering, AI-tracking av/på, og status. Hver driver har sin egen kø med tempogrense, slik at et kamera aldri får kommandoer raskere enn det tåler.

Fargematching

Fargematching gjøres i kameraene, styrt fra multiviewen: systemet måler alle bildene samtidig og justerer hvert kamera mot et referansekamera. ATEM Mini-serien har så vidt jeg vet ikke fargekorreksjon per inngang for kameraer fra andre merker, så korreksjonen må skje i kameraet.

1. **Lås kameraene:** slå av automatisk hvitbalanse og automatisk iris på alle, ellers overstyrer kameraet justeringene.

2. **Referanse i bildet:** sett et grått kort eller et fargekart der alle kameraene ser det, i showlyset.
3. **Mål:** systemet finner kortet i hver rute og regner ut avvik i hvitbalanse og lysstyrke mot referansekameraet.
4. **Juster og gjenta:** motoren sender kelvin eller R/B-gain og eksponering, måler på nytt og gjentar 3–5 ganger til avviket er under grensen.
5. **Lagre:** verdiene lagres per kamera og show-oppsett, og kan hentes med ett trykk neste gang.

Under sending endres aldri farge på et kamera som er på lufta. GUI-et viser bare et varsel hvis et kamera driver, og operatøren kan godkjenne en liten korreksjon mens kameraet er off air. Multiviewen er nedskalert, men fungerer for gjennomsnittsfarger på et kort. For finjustering av hudtoner må man se på et kamera i full oppløsning.

Oppsett for 1–4 deltakere

Alle har hver sin mic. Motoren velger regelsett ut fra antall deltakere i show-oppsettet, og samme oppsett lagrer kameraplan, vinkler og fargeverdier.

Deltakere	Kamera-plan (forslag)	Hva motoren gjør
1	2 kamera: nær + halvtotal	Ingen taler-bytter. Bytter vinkel i pauser hvert 12–25 s, og går til total ved stillhet
2	3 kamera: to nærbilder + to-skudd (eller SuperSource-split)	Krysstale og ping-pong går til to-skudd. Reaksjonsbilde er den andre personen
3	4 kamera: tre nærbilder + total	Krysstale går til total. Reaksjonsbilde velges blant to lyttere
4	5 kamera: fire nærbilder + total	Som for 3, men lengre bekreftelse ved avbrudd, fordi flere snakker i munnen på hverandre

Et PTZ-kamera kan dekke to roller, for eksempel nærbilde og total via presets, men bare hvis det får flytte seg mens det ikke er på lufta. ATEM Mini Extreme ISO har 8 innganger, så 5 kamera går fint.

Klipperegler

Tolv regler dekker det en erfaren bilderegissør gjør i en samtale med 2–4 personer. Verdiene er startpunkter for tuning i studio, ikke målte fasitsvar.

#	Regel	Hva den gjør	Rolig	Standard	Energisk
1	Aktiv tale	Mic er «aktiv» når VAD > terskel OG nivå ligger over alle andre mic-er med margin	VAD 0,7 · 9 dB	VAD 0,6 · 6 dB	VAD 0,5 · 4 dB
2	Bekreftelse	Ny taler må snakke sammenhengende så lenge før kutt	1200 ms	800 ms	500 ms
3	Minste bildelengde	Ingen nye kutt før bildet har stått så lenge	4,0 s	2,5 s	1,8 s
4	Småord-filter	Ytringer kortere enn dette («mm», «ja», latter) ignoreres	1,5 s	1,0 s	0,7 s
5	Krysstale	To eller flere aktive samtidig i mer enn X → to-skudd eller total	1,5 s	1,0 s	0,8 s
6	Ping-pong	Mer enn N bytter mellom samme to personer innen 10 s → to-skudd	3	4	5
7	Lang monolog	Etter X på samme taler → reaksjonsbilde av lytter i 2–3 s, så tilbake	25 s	15 s	10 s
8	Stillhet	Ingen aktiv mic: bli stående; etter X → total	4 s	3 s	2 s
9	Kutt-timing	Hvis gjeldende taler har en kort pause (> 150 ms) innenfor 300 ms, vent og kutt i pausen	på	på	av
10	Variasjon	Samme total/vinkel ikke to ganger på rad; vektet tilfeldig valg blant gyldige vinkler	på	på	på
11	PTZ-sikkerhet	Kamera på program flyttes aldri. Preset kjøres off air, og vinkel er ikke gyldig før den har «satt seg»	1,5 s	1,0 s	0,8 s
12	Prioritet	Vekt per person (vert, gjest), brukes når to er like sterke	vert 1,2	vert 1,1	1,0

Overstyring vinner alltid over regler: LÅS holder et kamera til det slippes, TOTAL NÅ tar total i ett bilde, og AUTO AV fryser motoren uten å endre noe på ATEM.

Hvert kutt logges med regelnummer og målte verdier, for eksempel: «KUTT → CAM2 · regel 2: Mic 2 aktiv 0,82 s (krav 0,80) · bildet hadde stått 3,4 s (krav 2,5)». Det er dette som gjør systemet mulig å tune.

Bilde-reglene virker oppå lydreglene. Er videolaget nede, faller motoren tilbake til bare lyd uten å stoppe.

#	Regel	Hva den gjør	Startverdi
V1	Munn bekrefter	Munnbevegelse i riktig kamera korter ned bekreftelsestiden; mic aktiv uten munnbevegelse i 400 ms regnes som lekkasje	Bekreftelse × 0,6
V2	Gyldig bilde	Ansikt må finnes, være innenfor bildet og ha riktig størrelse, ellers velges total eller to-skudd	±25 % av målstørrelse
V3	Beste reaksjon	Reaksjonsbilde velges etter høyest reaksjons-score blant lytterne	Siste 3 s
V4	Utsnitt off air	Kamera som ikke er på program justeres når feilen er stor nok, men fryses så snart det er kandidat til neste kutt	Feil > 8 % av bildehøyden
V5	Kamera i ro	Vinkel er gyldig først når bildet har stått stille	0,5 s
V6	Blikk (eksperimentell)	Taleren ser mot en person: den personens prioritet økes litt	Vekt × 1,1

GUI

Skjermen svarer på tre spørsmål til enhver tid: hva er på lufta, hva vil motoren gjøre neste, og hvorfor. Alt annet ligger i en innstillingsfane.

- **Program-feltet øverst:** stort navn på aktivt bilde (f.eks. «CAM 2 · Gjest nær»), hvor lenge det har stått, og en fremdriftslinje mot minste bildelengde.
- **Multiview med overlegg:** live miniatyr av hvert kamera med ansiktsboks, munn-indikator og et merke for gyldig bilde eller «justerer utsnitt».
- **Én stripe per mikrofon:** navn, nivåmåler, VAD-sannsynlighet, munnbevegelse fra kameraet og status med farge: stille, snakker, bekrefter (med nedtelling), ignorert som småord, ignorert som lekkasje.
- **«Neste beslutning»:** én setning, f.eks. «Venter: Mic 3 må snakke 0,3 s til».
- **Beslutningslogg:** siste 30 kutt med regel og målte verdier, nyeste øverst.

- **Tidslinje:** de siste 60 sekundene med tale per mic og kutt markert, slik at man ser om klippingen henger etter.
- **Store knapper:** AUTO på/av, TOTAL NÅ, LÅS, og ett trykk per kamera.
- **Tuning:** forhåndsvalg Rolig / Standard / Energisk + glidere for lyd- og bilde-reglene. Endringer gjelder umiddelbart og vises i loggen.
- **Oppsett:** kobling mic → person → kamera → vinkler, målstørrelse per vinkel, og en «kalibrer»-knapp der hver person snakker 5 sekunder.

En klikkbar prototype med simulert lyd viser dette i praksis, slik at reglene kan prøves før noe kobles til studio.

Byggeplan, risiko og test

Realistisk ramme er 6–8 uker for én erfaren utvikler til stabil live-drift med OBSBOT og Canon, der lyd og regler er i drift etter 4 uker og videolaget og fargematchingen legges på etterpå.

1. **Uke 1 – Lyd inn:** les RØDECaster via ASIO, kjør Silero VAD per kanal, vis meters i GUI. Mål lekkasje mellom mic-er i studio.
2. **Uke 2 – Regelmotor i skyggemodus:** regelsett for 1, 2, 3 og 4 deltakere. Motoren logger beslutninger live mens en person klipper manuelt, og loggene sammenlignes.
3. **Uke 3 – Companion og ATEM:** knapper per vinkel, tally tilbake, overstyring fra Stream Deck.
4. **Uke 4 – Kameradrivere og drift:** OBSBOT (VISCA + OSC) og Canon CR-N300 (XC). Presets, Windows-tjeneste, fallback til TOTAL. Første sendinger med bare lyd.
5. **Uke 5–6 – Videolaget:** multiview inn, ansikt og munn per rute, V1, V2 og V5. Mål ansiktsstørrelse i hver layout.
6. **Uke 7–8 – Utsnitt, reaksjoner og farge:** VISCA/XC-justering off air (V4), reaksjonsvalg (V3), fargematching mot referansekamera.
7. **Senere – Panasonic og Sony:** to nye drivere i samme mønster, ca. 1 uke hver inkludert test på ekte kamera.

Risiko	Konsekvens	Tiltak
Mye lekkasje mellom mic-er	Feil kutt ved krysstale	Dynamiske mic-er nær munn, gate på RØDECaster, målt lekkasjematrise, munn-bekreftelse (V1)

Risiko	Konsekvens	Tiltak
For små ansikter i multiview	Videolaget gir svake signaler	Færre ruter i multiview, eller kameraenes andre utgang inn i et capture-kort
Ulike kommandosett per kameramerke	En funksjon finnes ikke på alle	Felles driver med «støttes ikke»-svar; GUI viser hva hvert kamera kan
Automatikk i kameraet overstyrer	Farge og eksponering endrer seg	Alle kamera i manuell; motoren sjekker modus ved oppstart
ASIO låst av annet program	Motoren får ikke lyd	Motoren eier ASIO-enheten; opptak av lyd skjer i RØDECaster eller ATEM
Companion-forsinkelse eller frakobling	Kutt kommer sent eller ikke	Direkte ATEM-kutt som reserve; overvåk responstid
Firmware-endringer på ATEM eller kameraer	Kommandoer slutter å virke	Lås firmware i produksjon, test ved oppdatering
Utsnittsjustering når kameraet tas	Bildet beveger seg på lufta	V4 fryser kandidat-kameraer, V5 krever stillestående bilde

Testplan: kjør motoren i skyggemodus på tre live-sendinger mens en person klipper manuelt, og tell avvik per 10 minutter. Mål før motoren får klippe selv: færre enn 2 kutt per 10 minutter som operatøren ville gjort annerledes.

Åpne spørsmål: hvilke multiview-layouter brukes på ATEM i dag, og skal OBSBOT og Canon blandes i samme show? Blandet oppsett gjør fargematchingen viktigere.

Kilder

- VVD – Virtual Video Director
- Visual Radio Assist · Camera Assist · Companion-styring
- Broadcast Bionics CameraOne med RØDECaster · CameraOne pris
- multiCAM Radio · VidiGo · WinCam · ChyronHego · Broadcast Pix VOX
- RØDECaster Virtual Devices multitrack · RØDECaster USB-oppsett
- Companion HTTP Remote Control
- OBSBOT VISCA-guide · OBSBOT Tail 2 ressurser
- atem-connection · Silero VAD · LoCoNet

- RØDECaster Virtual Devices-driver og ASIO · ATEM Mini Extreme: utganger og multiview
- OBSBOT NDI-guide · OBSBOT OSC · Light-ASD
- Canon CR-N300 datablad · Cyanview: Canon XC-styring · Panasonic AW-UE150 grensesnitt · Sony BRC/SRG VISCA over IP